

PGMAT0061/MATG17 - Técnicas Computacionais em Estatística “Simulação Estocástica”

Professor responsável: Paulo Henrique Ferreira da Silva

Universidade Federal da Bahia
Instituto de Matemática e Estatística
Departamento de Estatística

21 de Janeiro de 2024

Métodos de Otimização Numérica

Otimização Numérica em Estatística:

Seja \mathcal{D} um domínio fechado e limitado em \mathbb{R}^S , e $f(x)$ é uma função contínua em \mathcal{D} . Queremos encontrar um ponto $x^* \in \mathcal{D}$ tal que:

$$M = f(x^*) = \max_{x \in \mathcal{D}} f(x)$$

Métodos de Otimização Numérica

i) Estimação por Máxima Verossimilhança:

x_1, \dots, x_n : amostra aleatória de uma fdp $g(\mathbf{x}|\theta)$, $\theta \in \Theta \subset \mathbb{R}$.

$$L(\theta) = \prod_{i=1}^n g(x_i|\theta)$$

Queremos encontrar $\hat{\theta} = \hat{\theta}_{MV}$, tal que:

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$$

OBS.: Em geral, $\hat{\theta}$ não tem expressão analítica ([ex:](#) Weibull, Beta etc.). Assim, $\hat{\theta}$ somente pode ser obtido por meio de **métodos numéricos**.

PROBLEMA: Em geral, $L(\theta)$ não é unimodal (máximos locais).

Métodos de Otimização Numérica

ii) Estatística do Teste da Razão de Verossimilhanças:

$$\begin{cases} H_0 : \theta \in \Theta_0 \\ H_1 : \theta \notin \Theta_0 \end{cases}, \quad \text{com } \Theta_0 \subset \Theta \subset \mathbb{R}$$

$$\underline{\text{TRV:}} \quad \lambda = -2 \log \left(\frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta} L(\theta)} \right) \quad \left(\stackrel{a}{\sim} \chi^2_\nu \right)$$

ν : diferença de dimensionalidade de Θ_0 e Θ

Métodos de Otimização Numérica

iii) Regressão Não Linear:

$$Y_i = h(\mathbf{x}_i, \boldsymbol{\theta}) + \epsilon_i, \quad i = 1, 2, \dots, n$$

em que $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^S$ é o vetor de parâmetros da regressão (ou coeficientes de regressão) e $h(\cdot)$ é alguma função.

$$\{(Y_i, \mathbf{x}_i) : i = 1, 2, \dots, n\}$$

$$Q(\boldsymbol{\theta}) = \sum_{i=1}^n (Y_i - h(\mathbf{x}_i, \boldsymbol{\theta}))^2$$

O estimador de mínimos quadrados $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}_{\text{MQ}}$ de $\boldsymbol{\theta}$ satisfaz:

$$Q(\hat{\boldsymbol{\theta}}) = \min_{\boldsymbol{\theta} \in \Theta} Q(\boldsymbol{\theta})$$

OBS: $\hat{\boldsymbol{\theta}}$ tem expressão analítica se $h(\cdot)$ é uma função linear de $\boldsymbol{\theta}$. Caso contrário, precisamos usar um **método numérico** em otimização não linear.

Métodos de Otimização Numérica

- **Métodos de Newton** \implies usam as derivadas de 1ª e 2ª ordens da função
- **Métodos de Quasi-Newton** \implies a matriz hessiana de derivadas segundas não precisa ser avaliada diretamente

Proposto simultaneamente (e de forma independente!) por Broyden, Fletcher, Goldfarb e Shanno em 1970, o método **BFGS** é um dos mais populares desta classe.

Método BFGS

Algoritmo:

- 1 Estabelecer um vetor de valores iniciais \mathbf{x}_0 e uma matriz hessiana aproximada B_0 ;
- 2 Obter uma direção de busca \mathbf{p}_k por resolver:

$$B_k \mathbf{p}_k = -\nabla f(\mathbf{x}_k)$$

- 3 Faça uma busca em linha para encontrar um tamanho de passo de descida aceitável α_k na direção encontrada no 2º passo. Então, atualize $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$;
- 4 Estabeleça $\mathbf{s}_k = \alpha_k \mathbf{p}_k$ e $\mathbf{y}_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$;
- 5 Calcule $B_{k+1} = B_k + \frac{\mathbf{y}_k \mathbf{y}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} - \frac{B_k \mathbf{s}_k \mathbf{s}_k^\top B_k^\top}{\mathbf{s}_k^\top B_k \mathbf{s}_k}$;
- 6 Tomar $k = k + 1$;
- 7 Repetir (2)-(6) enquanto $\|\nabla f(\mathbf{x}_k)\| > \epsilon$.

Método BFGS

OBS.:

- i) $f(\mathbf{x})$ é a função objetivo a ser minimizada;
- ii) Na prática, $B_0 = I$;
- iii) No 2º passo do algoritmo, toma-se a inversa da matriz B_k , que pode ser eficientemente obtida ao aplicar a fórmula de Sherman-Morrison no 5º passo do algoritmo, obtendo:

$$B_{k+1}^{-1} = \left(I - \frac{\mathbf{s}_k \mathbf{y}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} \right) B_k^{-1} \left(I - \frac{\mathbf{y}_k \mathbf{s}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k} \right) + \frac{\mathbf{s}_k \mathbf{s}_k^\top}{\mathbf{y}_k^\top \mathbf{s}_k}.$$

- v) No 3º passo, α_k deve satisfazer as condições padrões de Wolfe (1969):
 - C1) $f(\mathbf{x}_k + \alpha \mathbf{p}_k) \leq f(\mathbf{x}_k) + c_1 \alpha \mathbf{p}_k^\top \nabla f(\mathbf{x}_k)$, $c_1 \in (0, 1)$;
 - C2) $\mathbf{p}_k^\top \nabla f(\mathbf{x}_k + \alpha \mathbf{p}_k) \geq c_2 \mathbf{p}_k^\top \nabla f(\mathbf{x}_k)$, $c_2 \in (0, 1)$ e $0 < c_1 < c_2 < 1$.
- v) Em problemas de estimação na Estatística (tais como EMV e inferência Bayesiana), intervalos de confiança ou de credibilidade podem ser obtidos usando a inversa da matriz hessiana final (**cuidado!!!**)
- vi) No R: função `optim(., method="BFGS")`
 \Rightarrow usar `control=list(fnscale=-1)` p/ torná-lo um problema de maximização!

Método BFGS

Exercícios:

① $f(x_1, x_2) = x_1^2 + x_2^2 - 8x_1 + 5x_2 + 22,25$

② $f(x_1, x_2) = 10x_1^2 + x_2^2 - 8x_1 + 5x_2 + 22,25$

③ $f(x_1, x_2) = 9x_1^2 - 3x_1x_2 + 1,25x_2^2 - 24x_1 + 9x_2 + 22,25$

④ $f(x_1, x_2) = 0,5x_1^2 + 0,25x_2^2 + 20 \sin(0,1x_1x_2) + 0,25$

Se possível, representar graficamente a função e a solução encontrada pelo algoritmo.