

# PGMAT0061/MATG17 - Técnicas Computacionais em Estatística “Simulação Estocástica”

**Professor responsável:** Paulo Henrique Ferreira da Silva

Universidade Federal da Bahia  
Instituto de Matemática e Estatística  
Departamento de Estatística

23 de Janeiro de 2025

# Algoritmo EM

## Motivação:

- O algoritmo EM (do inglês *Expectation-Maximization*) pode ser aplicado em modelos de dados faltantes (*missing data models*);
- Esses modelos têm uma função de verossimilhança que pode ser expressa por:

$$f(\mathbf{x}|\boldsymbol{\theta}) = \int_{\mathcal{Z}} f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) d\mathbf{z}$$

Isto é, a função de interesse é a marginal de um modelo conjunto para  $(\mathbf{X}, \mathbf{Z})$ .

# Algoritmo EM

- É um método iterativo que calcula o estimador de máxima verossimilhança (EMV) em casos de dados faltantes ou incompletos;
- Transforma o problema de encontrar o máximo de uma função complicada em 2 problemas mais simples: **esperança (E)** e **maximização (M)**;
- Foi introduzido por Dempster, Laird e Rubin (1977).

# Algoritmo EM

Seja  $\mathbf{X} = (X_1, \dots, X_n)$  uma a.a. de  $X \sim f(x|\boldsymbol{\theta})$ , com  $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^p$ .

A função de verossimilhança é definida por:

$$L(\boldsymbol{\theta}|\mathbf{x}) = \prod_{i=1}^n f(x_i|\boldsymbol{\theta})$$

Queremos encontrar  $\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}|\mathbf{x})$ .

# Algoritmo EM

Considere as variáveis auxiliares (ou dados faltantes)  $\mathbf{Z} = (Z_1, \dots, Z_n)$  e seja  $f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta})$  a distribuição conjunta para  $(\mathbf{X}, \mathbf{Z})$ .

- Verossimilhança para **dados completos**:

$$L^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{z}) = f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta})$$

- Verossimilhança para **dados incompletos**:

$$L(\boldsymbol{\theta}|\mathbf{x}) = f(\mathbf{x}|\boldsymbol{\theta}) = \int_{\mathbf{Z}} f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) d\mathbf{z}$$

Sabemos que:  $f(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta}) = \frac{f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta})}{f(\mathbf{x}|\boldsymbol{\theta})}$ . Logo,

$$\begin{aligned}\log f(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta}) &= \log f(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) - \log f(\mathbf{x}|\boldsymbol{\theta}) \\ &= \ell^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{z}) - \ell(\boldsymbol{\theta}|\mathbf{x})\end{aligned}$$

# Algoritmo EM

Tomando a esperança na distribuição de  $\mathbf{Z}|\mathbf{x}, \boldsymbol{\theta}$  para  $\boldsymbol{\theta} = \boldsymbol{\theta}_0$ , obtemos:

$$\ell(\boldsymbol{\theta}|\mathbf{x}) = \mathbb{E}[\ell^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{z})|\mathbf{x}, \boldsymbol{\theta}_0] - \mathbb{E}[\log f(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta})|\mathbf{x}, \boldsymbol{\theta}_0]$$

Maximizar  $\ell(\boldsymbol{\theta}|\mathbf{x})$  equivale a maximizar somente:

$$\mathbb{E}[\ell^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{z})|\mathbf{x}, \boldsymbol{\theta}_0]$$

# Algoritmo EM

## Algoritmo EM:

- 1 (Passo E) Calcular:  $Q(\theta|\mathbf{x}, \hat{\theta}_{(k)}) = \mathbb{E}[\ell^c(\theta|\mathbf{x}, \mathbf{z})|\mathbf{x}, \hat{\theta}_{(k)}]$
- 2 (Passo M) Calcular:  $\hat{\theta}_{(k+1)} = \arg \max_{\theta} Q(\theta|\mathbf{x}, \hat{\theta}_{(k)})$

**OBS:** Repetir (1)-(2) até obter convergência, por exemplo,  $\|\hat{\theta}_{(k+1)} - \hat{\theta}_{(k)}\| < \epsilon$ , em que  $\epsilon$  é um valor determinado maior que 0.

# Algoritmo EM

Podemos mostrar que:

$$L(\hat{\theta}_{(k+1)}|\mathbf{x}) \geq L(\hat{\theta}_{(k)}|\mathbf{x})$$

com igualdade se, e somente se,

$$Q(\hat{\theta}_{(k+1)}|\mathbf{x}, \hat{\theta}_{(k)}) = Q(\hat{\theta}_{(k)}|\mathbf{x}, \hat{\theta}_{(k)})$$



# Algoritmo EM

## Exemplo: (modelo de mistura binomial)

Considere duas moedas com probabilidades de cara (desconhecidas), denotadas por  $p$  e  $q$ , respectivamente. A 1ª moeda é escolhida com probabilidade  $\pi$  e a 2ª moeda é escolhida com probabilidade  $1 - \pi$ . A moeda escolhida é lançada e o resultado é registrado.

Ex:  $\mathbf{x} = \{1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1\}$ , com: 1 = “cara”, 0 = “coroa”

Seja  $Z_i \in \{0, 1\}$  a moeda que foi usada no  $i$ -ésimo lançamento,  $i = 1, \dots, n$  (0 = “moeda 1”, 1 = “moeda 2”)

**Solução:**

$$\theta = (p, q, \pi)$$

$$\hat{\theta}_{\text{MV}} = \arg \max_{\theta} \log p(\mathbf{x}|\theta)$$

# Algoritmo EM

## 1 Passo E:

$$\begin{aligned}
 Q(\theta|\theta^{(k)}) &= \mathbb{E} \left[ \log \prod_{i=1}^n \left\{ \pi p^{x_i} (1-p)^{1-x_i} \right\}^{z_i} \left\{ (1-\pi) q^{x_i} (1-q)^{1-x_i} \right\}^{1-z_i} \right] \\
 &= \sum_{i=1}^n \left\{ \mathbb{E} \left[ Z_i | x_i, \theta^{(k)} \right] (\log \pi + x_i \log p + (1-x_i) \log(1-p)) \right. \\
 &\quad \left. + \left( 1 - \mathbb{E} \left[ Z_i | x_i, \theta^{(k)} \right] \right) (\log(1-\pi) + x_i \log q + (1-x_i) \log(1-q)) \right\}
 \end{aligned}$$

$$\begin{aligned}
 \mu_i^{(k)} &= \mathbb{E} \left[ Z_i | x_i, \theta^{(k)} \right] = p(z_i = 1 | x_i, \theta^{(k)}) \\
 &= \frac{p(x_i | z_i = 1, \theta^{(k)}) p(z_i = 1 | \theta^{(k)})}{p(x_i | \theta^{(k)})} \\
 &= \frac{\pi^{(k)} [p^{(k)}]^{x_i} [1 - p^{(k)}]^{1-x_i}}{\pi^{(k)} [p^{(k)}]^{x_i} [1 - p^{(k)}]^{1-x_i} + (1 - \pi^{(k)}) [q^{(k)}]^{x_i} [1 - q^{(k)}]^{1-x_i}}
 \end{aligned}$$

# Algoritmo EM

## 2 Passo M: (exercício)

$$\frac{\partial Q(\theta|\theta^{(k)})}{\partial \pi} = 0 \implies \pi^{(k+1)} = \frac{1}{n} \sum_i \mu_i^{(k)}$$

$$\frac{\partial Q(\theta|\theta^{(k)})}{\partial p} = 0 \implies p^{(k+1)} = \frac{\sum_i \mu_i^{(k)} x_i}{\sum_i \mu_i^{(k)}}$$

$$\frac{\partial Q(\theta|\theta^{(k)})}{\partial q} = 0 \implies q^{(k+1)} = \frac{\sum_i (1 - \mu_i^{(k)}) x_i}{\sum_i (1 - \mu_i^{(k)})}$$